

模式识别

张志飞

zhifeizhang@tongji.edu.cn

第二章 贝叶斯决策论

2.1 引例：鱼分拣

2.2 最小错误率贝叶斯决策

2.3 最小风险贝叶斯决策

2.4 分类器、判别函数

2.5 正态分布下的贝叶斯决策

2.6 离散变量的贝叶斯决策


总括

- 贝叶斯决策论是解决模式分类问题的一种基本统计途径。
- 出发点是利用概率决策与相应代价之间的折中。

它做了如下假设：

- 1)决策问题可以用概率形式来描述；
- 2)所有有关的概率结构均已知。

2.1 引例 鱼分拣




实现自动分拣的关键在于：
设计一个能分开两类鱼的分类器。

模式和模式识别

- 模式的两个层次：
 - 样本(sample,instance): 观测对象
 - 类别(class): 彼此相似的观测对象构成集合。
- 模式识别核心技术: **模式分类**
 - 检测: 2-class
 - 判别: 2-class, multi-class
 - 分类器设计: 机器学习
 - 相关问题: 特征提取、特征选择

8个样本, 2个类别



模式表示：两个方面



- 识别对象的表示：

- 特征向量: $x = [x_1, x_2, \dots, x_n]^T$ x_1 亮度、 x_2 宽度
- 特征空间: 一个模式(样本)对应空间中的一点
- 好处: 容易计算样本之间的距离/相似度
- 问题: 特征提取、特征选择

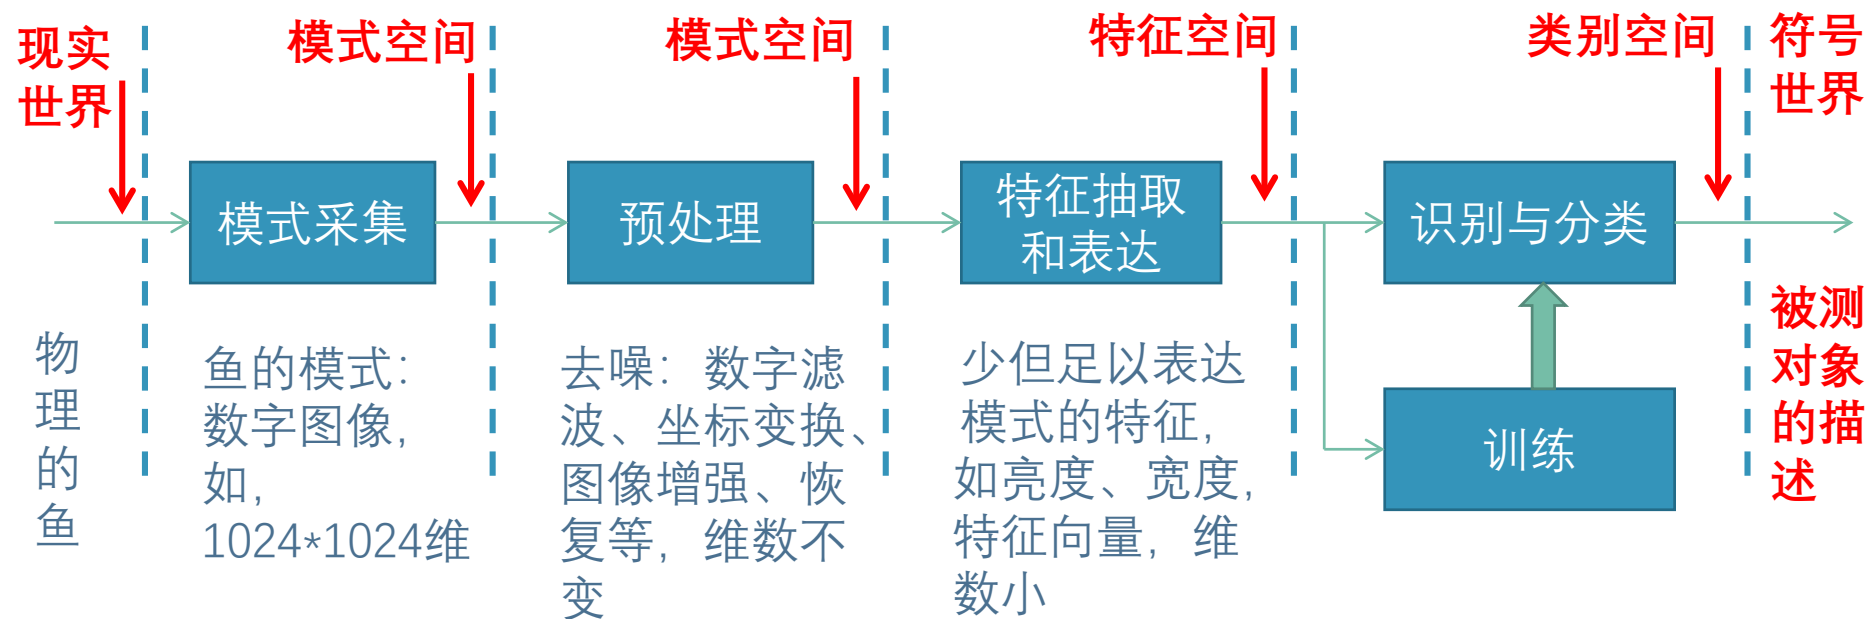
分类问题 → 特征空间划分问题

- **分类器的表示:**

- 类别模型: $M_i=M(\mathbf{x},\theta_i)$
- 判别函数: $y_i=f(\mathbf{x},\mathbf{w}_i)$
- 决策面: $f(\mathbf{x},\mathbf{w}_j) = f(\mathbf{x},\mathbf{w}_j)$



模式识别系统的基本构成



根据特征向量在特征空间中的分布，划分特征空间，使得每一区域尽可能只包含来自同一个类别的样本。建立特征空间中的一个分割区域与一个类别之间的关联。获取这种关联关系的过程称为**训练**。根据训练结果，由新样本落在特征空间的区域决定其类别，这称为**分类或识别**。

规范化描述

- 类别: $\omega_1, \dots, \omega_c$ 表示 c 个类别的有限集
- 特征向量: $\mathbf{x} = (x_1, x_2, \dots, x_d)^T \in \mathbf{R}^d$
- 先验概率: $p(\omega_j)$ $\sum_{i=1}^c P(\omega_i) = 1$
- 类(条件)概率密度: $p(\mathbf{x}|\omega_j)$
- 后验概率, 可由**贝叶斯公式**计算,

$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j) P(\omega_j)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | \omega_j) P(\omega_j)}{\sum_{j=1}^c p(\mathbf{x} | \omega_j) P(\omega_j)}$$

$$\sum_{i=1}^c P(\omega_i | \mathbf{x}) = 1$$

2.2 最小错误率决策：鱼分拣

- 鲈鱼 ω_1 ，鲑鱼 ω_2
- 若仅知道两种鱼先验概率，如何判定一新到鱼 x 的类别？判错概率？

如果 $P(\omega_1) > P(\omega_2)$ ，则 $x \in \omega_1$ ； 否则， $x \in \omega_2$ (2-1)

$$\because P(\omega_1) + P(\omega_2) = 1,$$


$$\therefore P(error) = \begin{cases} P(\omega_2), & \text{若决策 } x \in \omega_1 \\ P(\omega_1), & \text{若决策 } x \in \omega_2 \end{cases}$$

显然，采用式(2-1)的决策犯错误的概率最小。 $\min\{P(\omega_1), P(\omega_2)\}$

- 在所有可能出现的样本上类别决策错误的概率被称为**错误率**。
- 式(2-1)的准则实际上是最小错误率准则。


若观测到鱼的光泽度 x ?

观测量分布 $p(x|\omega_i)$



x轴：一维特征空间

计算后验概率



$$P(\omega_i | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_i)P(\omega_i)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | \omega_i)P(\omega_i)}{\sum_{j=1}^c p(\mathbf{x} | \omega_j)P(\omega_j)}$$

贝叶斯公式

- $p(x) = \sum_j p(x|\omega_j) P(\omega_j)$ 是归一化因子(也称**证据因子**)，与类别状态无关。
- $p(x|\omega_j)$ 为 ω_j 关于 x 的**似然函数**，表明在其他条件都相等的情况下，使得 $p(x|\omega_j)$ 较大的 ω_j 更有可能是真实的类别。

$$P(x, \omega_j) = P(\omega_j|x)p(x) = p(x|\omega_j)P(\omega_j)$$



$$P(\omega_j|x) = \frac{p(x|\omega_j)P(\omega_j)}{p(x)}$$

$$\text{后验} = \frac{\text{似然} \times \text{先验}}{\text{证据}}$$

基于后验概率决策

- 对某一观测 x ,
 - 如果 $P(\omega_1|x) > P(\omega_2|x)$, 则判为 ω_1 ; 否则, 判为 ω_2 。 (2-2)

- 判错概率: $P(error|x) = \begin{cases} P(\omega_1|x) & \text{如果决策 } x \in \omega_2 \\ P(\omega_2|x) & \text{如果决策 } x \in \omega_1 \end{cases}$ (2-3)

- **错误率：平均错误概率**，定义为独立同分布样本错误概率的期望，即

$$P(error) = \int_{-\infty}^{\infty} P(error, x) dx = \int_{-\infty}^{\infty} P(error|x) p(x) dx \quad (2-4)$$

- 式(2-2)仍然是最小错误率的决策，因为它保证了对每一个 x , $P(error|x)$ 最小。

最小错误率贝叶斯决策：两类情况

- 从最小错误率的要求出发，利用贝叶斯公式，就能得出使错误率最小的分类决策，称之为**最小错误率贝叶斯决策**。
- 根据式(2-3)可知，使**错误率最小的决策**就是**使后验概率最大的决策**。

对两类问题，最小错误率贝叶斯决策规则：

如果 $P(\omega_1|x) > P(\omega_2|x)$ ，则 $x \in \omega_1$ ；反之，则 $x \in \omega_2$ 。

等价形式

(1) 若 $P(\omega_i|x) = \max_{j=1,2} P(\omega_j|x)$ ，则 $x \in \omega_i$

(2) 若 $p(x|\omega_i)P(\omega_i) = \max_{j=1,2} P(x|\omega_j)p(\omega_j)$ ，则 $x \in \omega_i$

(3) 似然比 $l(x)$ ，若 $l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \geq \frac{P(\omega_2)}{P(\omega_1)}$ ，则 $x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

(4) 对数似然比，取 $h(x) = \ln \frac{P(x|\omega_1)}{P(x|\omega_2)} + \ln \frac{P(\omega_1)}{P(\omega_2)}$

决策边界

判决门限为 t
 Ω_1 为 $(-\infty, t)$
 Ω_2 为 (t, ∞)




图2-1基于最小错误率的贝叶斯决策

计算错误率

写成

$$\begin{aligned} P(e) &= \int_{-\infty}^t P(\omega_2|x) p(x) dx + \int_t^{\infty} P(\omega_1|x) p(x) dx \\ &= \int_{-\infty}^t p(x|\omega_2) P(\omega_2) dx + \int_t^{\infty} p(x|\omega_1) P(\omega_1) dx \end{aligned}$$

$$\begin{aligned} P(e) &= P(x \in \Omega_1, \omega_2) + P(x \in \Omega_2, \omega_1) \\ &= P(x \in \Omega_1|\omega_2)P(\omega_2) + P(x \in \Omega_2|\omega_1)P(\omega_1) \\ &= P(\omega_2) \int_{\Omega_1} p(x|\omega_2) dx + P(\omega_1) \int_{\Omega_2} p(x|\omega_1) dx \\ &= \mathbf{P(\omega_2)\epsilon_{21} + P(\omega_1)\epsilon_{12}} \end{aligned}$$

其中, $\epsilon_{21} = \int_{\Omega_1} p(x|\omega_2) dx$, 把第二类样本决策为第一类的错误率;
 $\epsilon_{12} = \int_{\Omega_2} p(x|\omega_1) dx$, 把第一类样本决策为第二类的错误率。

两种错误率用相应类别的先验概率加权, 就是总的平均错误率。

例2.1 垃圾邮件过滤

一封电子邮件不是垃圾邮件就是正常邮件，我们用 ω_1 、 ω_2 分别代表垃圾和正常邮件，各自取值的概率分别为 $P(\omega_1)$ ， $P(\omega_2)$ 。

设 $\{w_1, \dots, w_n\}$ 代表一些特殊的词(或词的组合)形成的集合，它们出现后就表示邮件是垃圾的。对每个 $i(i=1, \dots, n)$ ， X_i 是伯努利随机变量，用来定义词汇 w_i 是否出现在信息中，即当 w_i 出现时， $X_i = 1$ ，否则 $X_i = 0$ 。

假设条件概率 $p(x_i|\omega_1)$ 和 $p(x_i|\omega_2)$ 已知， $x_i = 0, 1$ 。简单起见，假设在给类别 ω_j 的条件下随机变量 X_1, \dots, X_n 是相互独立的。

现在想根据响应向量 (x_1, \dots, x_n) ，判断一封邮件是垃圾还是正常邮件。

例2.1 (续)

用贝叶斯公式，计算两类邮件的后验概率，

$$P(\omega_m | X_1 = x_1, \dots, X_n = x_n) = \frac{P(\omega_m) \prod_{i=1}^n p(x_i | \omega_m)}{\sum_{j=1}^2 p(\omega_j) \prod_{i=1}^n p(x_i | \omega_j)}, \quad m = 1, 2$$

若下式成立，则判定**该邮件**为垃圾邮件：

$$P(\omega_1 | X_1 = x_1, \dots, X_n = x_n) > P(\omega_2 | X_1 = x_1, \dots, X_n = x_n)$$

或等价地

$$P(\omega_1) \prod_{i=1}^n p(x_i | \omega_1) > P(\omega_2) \prod_{i=1}^n p(x_i | \omega_2)$$

最小错误率贝叶斯决策：多类情况

决策规则：

如果 $P(\omega_i|x) = \max_{j=1,\dots,c} P(\omega_j|x)$, 则 $x \in \omega_i$

等价形式

若 $p(x|\omega_i)P(\omega_i) = \max_{j=1,\dots,c} P(x|\omega_j)p(\omega_j)$, 则 $x \in \omega_i$

错误率：

- 直接计算的计算量大。因为特征空间被分割成c个区域，可能错误的情况c(c-1)种。
- 通过计算平均正确率 $P(c)$ 来计算错误率。

$$P(c) = \sum_{j=1}^c P(x \in \Omega_j | \omega_j) P(\omega_j) = \sum_{j=1}^c \int_{\Omega_j} p(x | \omega_j) P(\omega_j) dx$$

$$P(e) = 1 - P(c) = 1 - \sum_{j=1}^c P(\omega_j) \int_{\Omega_j} p(x | \omega_j) dx$$

2.3 最小风险贝叶斯决策

- 很多场合，不同的错误决策所造成的损失不同
 - 癌症误判、鱼分拣
- 引入更一般的损失函数来替代错误率
 - 计算各种不同误判的风险；采取总风险最小的决策。最小风险贝叶斯决策
- 允许更多行动(action)而不仅仅是类别判定
 - 当决策风险大于不决策时，可以拒绝做决策。

判决的风险

- 决策代价(loss)

- 对某样本 \mathbf{x} ，真实类别状态为 ω_j 而决策为 α_i 的损失函数 $\lambda(\alpha_i|\omega_j)$

- 条件风险(Condition risk)，某样本 \mathbf{x} 属于各个状态的后验概率是 $P(\omega_j|\mathbf{x})$ ， $j=1,\dots,c$ ，对它采取决策 α_i 的期望损失，

$$R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\mathbf{x})$$

- 总的风险， $R = \int R(\alpha(\mathbf{x})|\mathbf{x})p(\mathbf{x})d\mathbf{x}$ ← 最小化

- $p(\mathbf{x})$ 已知且与决策无关，因此，要使积分和最小，每个 \mathbf{x} 都使 $R(\alpha(\mathbf{x})|\mathbf{x})$ 最小。

- 最小风险贝叶斯决策就是

若 $R(\alpha_i|\mathbf{x}) = \min_{j=1\dots c} R(\alpha_j|\mathbf{x})$ ，则采取决策 α_i

最小风险决策：两类问题

- 计算条件风险：
$$\begin{aligned} R(\alpha_1|\mathbf{x}) &= \lambda_{11}P(\omega_1|\mathbf{x}) + \lambda_{12}P(\omega_2|\mathbf{x}) \\ R(\alpha_2|\mathbf{x}) &= \lambda_{21}P(\omega_1|\mathbf{x}) + \lambda_{22}P(\omega_2|\mathbf{x}) \end{aligned}$$
 其中 $\lambda_{ij} = \lambda(\alpha_i|\omega_j)$

- 最小风险贝叶斯决策：

若 $R(\alpha_1|\mathbf{x}) < R(\alpha_2|\mathbf{x})$, 则判为 ω_1 。

等价地,

若 $(\lambda_{21} - \lambda_{11})P(\omega_1|\mathbf{x}) > (\lambda_{12} - \lambda_{22})P(\omega_2|\mathbf{x})$, 则判为 ω_1 。

或写成“似然比”，

若 $\frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \frac{P(\omega_2)}{P(\omega_1)}$, 则判为 ω_1 。

最小风险贝叶斯决策与最小错误率贝叶斯决策

- 当 $\lambda_{11} = \lambda_{22} = 0, \lambda_{12} = \lambda_{21} = 1$ 时，最小风险贝叶斯决策就转化成最小错误率贝叶斯决策。
- 可以把最小错误率贝叶斯决策看作最小风险贝叶斯决策的特例，是0-1损失时的最小风险贝叶斯决策。

例2.2 比较两种贝叶斯决策

假设在某个地区细胞识别中正常(ω_1)和异常(ω_2)两类的先验概率分别为,

$$\text{正常状态} \quad P(\omega_1) = 0.9$$

$$\text{异常状态} \quad P(\omega_2) = 0.1$$

已知正确决策没有损失, 错误决策损失分别为,

对真实状态为正常(ω_1)的细胞, 决策为 α_2 的损失为1, 即 $\lambda_{21} = 1$

对真实状态为异常(ω_2)的细胞, 决策为 α_1 的损失为6, 即 $\lambda_{12} = 6$

现有一待识别的细胞, 其观测值为 x , 从类条件概率曲线上分别查得,

$$p(x|\omega_1)=0.2, \quad p(x|\omega_2)=0.4$$

试分别用最小错误率贝叶斯决策和最小风险贝叶斯决策对该细胞 x 进行分类。

例2.2 (续)

最小错误率贝叶斯决策：

利用贝叶斯公式计算后验概率，

$$P(\omega_1|x) = \frac{0.2 \times 0.9}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.818$$

$$P(\omega_2|x) = 1 - P(\omega_1) = 0.182$$

根据最小错误率贝叶斯决策规则，因

$$P(\omega_1|x) > P(\omega_2|x)$$

把 x 归为正常状态，属于 ω_1 类。

最小风险贝叶斯决策：

利用贝叶斯公式计算后验概率，

$$P(\omega_1|x) = 0.818, \quad P(\omega_2|x) = 0.182$$

计算条件风险，

$$R(\alpha_1|x) = \sum_{j=1}^2 \lambda_{1j} P(\omega_j|x) = \lambda_{12} P(\omega_2|x) = 1.092$$

$$R(\alpha_2|x) = \lambda_{21} P(\omega_1|x) = 0.818$$

由于 $R(\alpha_1|x) > R(\alpha_2|x)$ ，根据最小风险贝叶斯决策，我们把 x 归为异常，属于 ω_2 类。

带拒识的决策

- 根据最小风险贝叶斯决策规则，若分类的风险大于不作决策的风险，可考虑拒绝分类。
- 定义**拒绝域**， $\mathcal{R} = \{\mathbf{x} | \min_i R(\omega_i | \mathbf{x}) > t\}$ ，其中 t 为阈值。
- 决策规则，

若 $R(\omega_i | \mathbf{x}) = \min_j R(\omega_j | \mathbf{x}) \leq t$ ，则接受 x 并将其归入 ω_i ；

否则，拒绝对 x 做出决策。

2.4 分类器、判别函数和决策面

- **分类器**的表示方式有多种，最常用的是一组判别函数。
- 设类别 ω_i 对应**判别函数** $g_i(\mathbf{x})$, $i = 1, 2, \dots, c$ 。给定一特征向量 \mathbf{x} ，在最大值判决下，判决规则为，

若 $g_i(\mathbf{x}) > g_j(\mathbf{x})$, $\forall j \neq i, j = 1, 2, \dots, c$, 则 $\mathbf{x} \in \omega_i$ 。

- 判决规则将特征空间分成 c 个判决区域， $\mathcal{R}_1, \dots, \mathcal{R}_c$ 。若对 $\forall j \neq i$ 有 $g_i(\mathbf{x}) > g_j(\mathbf{x})$ ，那么 \mathbf{x} 属于 \mathcal{R}_i 。此区域由判决边界来分割。
- **判别边界**即判决空间中使判别函数值最大的曲面(**决策面**)。

分类器可视为一个网络或机器，对每个输入 $\mathbf{x} = (x_1, x_2, \dots, x_d)^T$ ，通过计算 c 个判别函数，选择与最大判别值相对应的类别。如图2-2




图2-2 统计模式分类器的一般结构

贝叶斯分类器的判别函数

- 对于**最小错误率**的情况，取

$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x})$$

这样，最大判别函数即为最大后验概率。

- 一般**有风险**的情况下，取

$$g_i(\mathbf{x}) = -R(\alpha_i|\mathbf{x})$$

因为，最大判别函数等价于最小条件风险。

判别函数的性质

- 判别函数的单调增函数不改变分类结果。即

若 $f(\cdot)$ 是一个单调增函数，则 $f(g_i(\mathbf{x}))$ 与 $g_i(\mathbf{x})$ 分类结果相同。

可利用该性质构造更简单的判别函数。如最小错误率分类判别函数，

$$g_i(\mathbf{x}) = P(\omega_i|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_i)P(\omega_i)}{P(\mathbf{x})}$$

$$g_i(\mathbf{x}) = p(\mathbf{x}|\omega_i)P(\omega_i)$$

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i)$$

2.5 正态分布下的贝叶斯决策

- 正态 (高斯) 分布及其性质回顾
 - 单变量正态密度函数

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$

式中 μ 、 σ^2 、 σ 分别是随机变量 x 的期望、方差和标准差。

$$\mu = E\{x\} = \int_{-\infty}^{\infty} xp(x)dx$$

$$\sigma^2 = E\{(x - \mu)^2\} = \int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx$$

单变量高斯概率密度函数由参数 μ 和 σ^2 完全确定，常简记 $p(x)$ 为 $N(\mu, \sigma^2)$

– 多元正态密度函数

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

式中 $\mathbf{x} = (x_1, x_2, \dots, x_d)^T$ 是 d 维随机向量, $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_d)^T$ 是 \mathbf{x} 的均值向量, $\boldsymbol{\Sigma}$ 是 \mathbf{x} 的 $d \times d$ 维协方差矩阵, $\boldsymbol{\Sigma}^{-1}$ 和 $|\boldsymbol{\Sigma}|$ 分别是 $\boldsymbol{\Sigma}$ 的逆矩阵和行列式。

$$\mu_i = E\{x_i\} = \int_{-\infty}^{\infty} x_i p(x_i) dx_i$$

其中 $p(x_i) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} p(\mathbf{x}) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_d$

$$\begin{aligned} \boldsymbol{\Sigma} &= E\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T\} \\ &= \begin{bmatrix} \sigma_{11}^2 & \sigma_{12}^2 & \dots & \sigma_{1d}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 & \dots & \sigma_{2d}^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1}^2 & \sigma_{d2}^2 & \dots & \sigma_{dd}^2 \end{bmatrix} \end{aligned}$$

$$\sigma_{ij}^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x_i - \mu_i)(x_j - \mu_j) p(x_i, x_j) dx_i dx_j = \sigma_{ji}^2$$

其中 $p(x_i, x_j) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} p(\mathbf{x}) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_{j-1} dx_{j+1} \dots dx_d$

正态分布下的最小错误率判别函数

- 取最小错误率贝叶斯判别函数如下，

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i)$$

- 对多元正态概型 $p(\mathbf{x}|\omega_i) \sim N(\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$, $i = 1, \dots, c$, 判别函数通式 如下，

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

第1项

第2项

第3项

第4项

情况1: $\Sigma_i = \sigma^2 I$

- 协方差阵是对角阵

- 最简单情况。发生在各特征独立且具有相同方差 σ^2 时。样本呈球状分布。
- 有 $|\Sigma_i| = \sigma^{2d}$, $\Sigma_i^{-1} = (1/\sigma^2)I$

- 判别函数:

$$g_i(\mathbf{x}) = -\frac{\|\mathbf{x} - \boldsymbol{\mu}_i\|^2}{2\sigma^2} + \ln P(\omega_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i|$$

与i无关, 故
可省略

其中 $\|\cdot\|$ 是欧氏范数, $\|\mathbf{x} - \boldsymbol{\mu}_i\|^2 = (\mathbf{x} - \boldsymbol{\mu}_i)^T (\mathbf{x} - \boldsymbol{\mu}_i)$

$$g_i(\mathbf{x}) = -\frac{\|\mathbf{x} - \boldsymbol{\mu}_i\|^2}{2\sigma^2} + \ln P(\omega_i)$$

- 将二次型 $(\mathbf{x} - \boldsymbol{\mu}_i)^T (\mathbf{x} - \boldsymbol{\mu}_i)$ 展开, 得

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2} (\mathbf{x}^T \mathbf{x} - 2\boldsymbol{\mu}_i^T \mathbf{x} + \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i) + \ln P(\omega_i)$$

由于所有类别的判别函数中均包含 $\mathbf{x}^T \mathbf{x}$ 项, 可省略。最终的判别函数可写成,

$$g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0} \quad \leftarrow \text{判别函数 } g_i(x) \text{ 是 } \mathbf{x} \text{ 的线性函数,}$$

$$\text{其中, } \mathbf{w}_i = \frac{1}{\sigma^2} \boldsymbol{\mu}_i$$

称 w_{i0} 为第 i 个方向上的偏置

$$w_{i0} = -\frac{1}{2\sigma^2} \boldsymbol{\mu}_i^T \boldsymbol{\mu}_i + \ln P(\omega_i)$$

- 判别函数为线性函数的分类器称为**线性分类器**。
- 线性分类器的决策面是由线性方程

$$g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0$$

所确定的一个**超平面**（如果决策域 \mathcal{R}_i 和 \mathcal{R}_j 相邻）。

- 对于 $\Sigma_i = \sigma^2 I$ 的正态密度情况，**决策面方程**可改写为

$$\mathbf{w}^T (\mathbf{x} - \mathbf{x}_0) = 0$$

—— 一个过点 \mathbf{x}_0 且与权向量 \mathbf{w} 正交的超平面

$$\mathbf{w} = \boldsymbol{\mu}_i - \boldsymbol{\mu}_j$$

—— 将 \mathcal{R}_i 与 \mathcal{R}_j 分开的超平面与两均值向量的连线垂直

$$\mathbf{x}_0 = \frac{1}{2} (\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\sigma^2}{\|\boldsymbol{\mu}_i - \boldsymbol{\mu}_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$$

—— 若 $P(\omega_i) = P(\omega_j)$, 平分; 若不等, 则判定边界远离先验概率大的类别。

对高斯分布，情况1: $\Sigma_i = \sigma^2 I$

若所有 c类的先验概率 $P(\omega_i)$ 相等，则判别函数简化为，


$$g_i(\mathbf{x}) = -\|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

判决规则为：


为将某特征向量 \mathbf{x} 归类，通过测量每一 \mathbf{x} 到c个均值向量中的每一个的欧氏距离，将 \mathbf{x} 归为离它最近的那一类中。

最近邻算法


一维



二维



三维


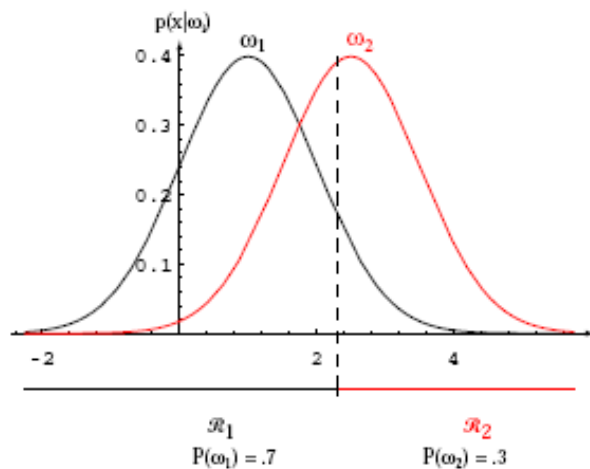


如果两种分布的协方差矩阵相等，且与单位阵成比例，那么它们呈d维球状分布，其判别边界是一个d-1维归一化超平面，垂直于两个中心的连线。



在这些一维、二维、三维的例子中，假设 $P(\omega_1) = P(\omega_2)$

边界垂直平分两类中心(均值向量)



一维



二维



三维



随着先验概率的改变，判决边界也随之改变。
对于差别较大的离散先验概率，判决边界不会落于球状高斯分布的中心点之间。

情况2: $\Sigma_i = \Sigma \neq$ 对角阵的情况

- 判别函数: 省略正态概型判别函数通式中的第1、2项, 得

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) + \ln P(\omega_i)$$

- 二次型展开后, 去掉与 i 无关项 $\mathbf{x}^T \Sigma^{-1} \mathbf{x}$, 得如下线性判别函数,

$$g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0}$$

其中,

$$\mathbf{w}_i = \Sigma^{-1} \boldsymbol{\mu}_i$$

$$w_{i0} = \frac{-1}{2} \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i + \ln P(\omega_i)$$

- 决策面方程：超平面

$$\mathbf{w}^T (\mathbf{x} - \mathbf{x}_0) = 0$$

其中， $\mathbf{w} = \Sigma^{-1}(\mu_i - \mu_j)$ ——— 将 \mathcal{R}_i 与 \mathcal{R}_j 分开的超平面与两均值向量连线未必垂直

$$\mathbf{x}_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\ln[P(\omega_i)/P(\omega_j)]}{(\mu_i - \mu_j)^T \Sigma^{-1}(\mu_i - \mu_j)} (\mu_i - \mu_j)$$

若 $P(\omega_i) = P(\omega_j)$, 则决策面过两均值向量连续的中点，即平分；若不等，则判定边界向先验概率小的均值点偏移。

对高斯分布，情况2: $\Sigma_i = \Sigma$

若c类先验概率都相等，则判别函数简化为，

$$g_i(\mathbf{x}) = -\gamma^2 = -(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)$$

此时决策规则：

为对某样本 \mathbf{x} 进行分类，通过计算 \mathbf{x} 到每类的均值向量的马氏距离 γ^2 ，将 \mathbf{x} 归于 γ^2 最小的类别。

最近邻算法

情况3: $\Sigma_i = \text{任意}$

- 一般的多元正态分布情况, 判别函数通式中只有 $\frac{d}{2} \ln 2\pi$ 与 i 无关, 可省略。简化后,

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

- 判别函数是二次函数:

$$g_i(\mathbf{x}) = \mathbf{x}^T \mathbf{W}_i \mathbf{x} + \mathbf{w}_i^T \mathbf{x} + w_{i0} \quad (1)$$


其中, $\mathbf{W}_i = -\frac{1}{2} \boldsymbol{\Sigma}_i^{-1} \quad (d \times d \text{ 矩阵}) \quad (2)$

$$\mathbf{w}_i = \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i \quad (d \text{ 维列向量}) \quad (3)$$

$$w_{i0} = \frac{-1}{2} \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i) \quad (4)$$

- 判别边界: 超二次曲面

例2.3 二维高斯分布数据的判决边界



已知

- ω_1 表示黑点的集合,

$$\mathbf{a}_1 = \begin{bmatrix} 2 \\ 6 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 4 \\ 6 \end{bmatrix}, \mathbf{a}_3 = \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \mathbf{a}_4 = \begin{bmatrix} 3 \\ 8 \end{bmatrix}$$

- ω_2 是红点的集合,

$$\mathbf{a}_5 = \begin{bmatrix} 3 \\ 0 \end{bmatrix}, \mathbf{a}_6 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, \mathbf{a}_7 = \begin{bmatrix} 5 \\ -2 \end{bmatrix}, \mathbf{a}_8 = \begin{bmatrix} 3 \\ -4 \end{bmatrix}$$

(1) 假设两类的先验概率相等, 求决策面方程。

(2) 判别点 $(2, 2)^T$ 所属类别。

$$g_i(\mathbf{x}) = \mathbf{x}^T \mathbf{W}_i \mathbf{x} + \mathbf{w}_i^T \mathbf{x} + w_{i0}$$

$$\mathbf{W}_i = -\frac{1}{2} \boldsymbol{\Sigma}_i^{-1} \quad (d \times d \text{ 矩阵})$$

$$\mathbf{w}_i = \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i \quad (d \text{ 维列向量})$$

$$w_{i0} = \frac{-1}{2} \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

(1)

(2)

(3)

(4)

- 均值 μ_i 和协方差 Σ_i , $i=1,2$, 用下式计算,

$$\mu_1 = \frac{1}{4} \sum_{k=1}^4 \mathbf{a}_k, \quad \Sigma_1 = \frac{1}{4} \sum_{k=1}^4 (\mathbf{a}_k - \mu_1)(\mathbf{a}_k - \mu_1)^T$$

$$\mu_2 = \frac{1}{4} \sum_{k=5}^8 \mathbf{a}_k, \quad \Sigma_2 = \frac{1}{4} \sum_{k=5}^8 (\mathbf{a}_k - \mu_2)(\mathbf{a}_k - \mu_2)^T$$

得,

$$\mu_1 = \begin{pmatrix} 3 \\ 6 \end{pmatrix} \quad \Sigma_1 = \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix} \quad \Sigma_1^{-1} = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix} \quad |\Sigma_1| = 1$$

$$\mu_2 = \begin{pmatrix} 3 \\ -2 \end{pmatrix} \quad \Sigma_2 = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \quad \Sigma_2^{-1} = \begin{pmatrix} 1/2 & 0 \\ 0 & 1/2 \end{pmatrix} \quad |\Sigma_2| = 4$$

- 把 $P(\omega_1) = P(\omega_2) = 0.5$ 代入一般形式的判别式(1)~(4),

$$W_1 = \begin{pmatrix} -1 & 0 \\ 0 & -0.25 \end{pmatrix} \quad W_2 = \begin{pmatrix} -0.25 & 0 \\ 0 & -0.25 \end{pmatrix} \quad w_1 = \begin{pmatrix} 6 & 3 \\ 1.5 & -1 \end{pmatrix} \quad w_{10} = -18.6931$$

$$w_2 = \begin{pmatrix} 6 & 3 \\ 1.5 & -1 \end{pmatrix} \quad w_{20} = -4.6363$$

- 得
$$g_1 = -1.0*x_1**2 + 6.0*x_1 - 0.25*x_2**2 + 3.0*x_2 - 18.6931471805599$$
$$g_2 = -0.25*x_1**2 + 1.5*x_1 - 0.25*x_2**2 - 1.0*x_2 - 4.63629436111989$$

$$g_1(\mathbf{x}) = -x_1^2 + 6x_1 - 0.25x_2^2 + 3x_2 - 18.6931$$

$$g_2(\mathbf{x}) = -0.25x_1^2 + 1.6x_1 - 0.25x_2^2 - x_2 - 4.6363$$

- 令 $g_1(\mathbf{x}) = g_2(\mathbf{x})$ ，得判决边界为，

$$x_2 = 3.514 - 1.125x_1 + 0.1875x_1^2$$

此方程描述了一个顶点位于 $(3, 1.83)^T$ 的抛物线。

- 当 $\mathbf{x} = (2, 2)^T$ 时， $g_1 < g_2$ ，故判定 \mathbf{x} 属于 ω_2 。

输入：训练数据集 $D = \{(x_1, y_1), \dots, (x_N, y_N)\}$ 各分量为连续型数据

过程：

(1) 计算先验概率 $p(y=c_k)$ 的极大似然估计：

$$\hat{p}(y=c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda}, k = 1, 2, \dots, K$$

其中 I 是指示性函数，若 $y_i = c_k$ ，则 $I(y_i = c_k) = 1$ ，否则 $I(y_i = c_k) = 0$

λ 是平滑项， $\lambda = 1$ 时则是拉普拉斯平滑，这里 $\lambda = 1$ 。

(2) 计算条件概率密度 $p(X^{(j)}=a_{jl}|y=c_k)$ ：

$$p(X^{(j)}=a_{jl}|y=c_k) = \frac{1}{\sqrt{2\pi}\sigma_{jk}} e^{-\frac{(a_{jl}-u_{jk})^2}{2\sigma_{jk}^2}}$$

这里有两个参数 u_{jk} 、 σ_{jk} ，它们可以用极大似然估计法定出：

$$\hat{u}_{jk} = \frac{1}{N_k} \sum_{i=1}^N x_i^{(j)} I(y_i = c_k)$$

$$\hat{\sigma}_{jk}^2 = \frac{1}{N_k} \sum_{i=1}^N (x_i^{(j)} - u_{jk})^2 I(y_i = c_k)$$

其中， $N_k = \sum_{i=1}^N I(y_i = c_k)$ 是类别 c_k 的样本数。

(3) 构造决策函数 $f(x)$ （根据贝叶斯决策，数据 $x^* = (x^{*(1)}, \dots, x^{*(n)})^T$ 的类别应判定为后验概率最大的类别）：

$$f(x^*) = \arg \max_{c_k} \hat{p}(y = c_k) \prod_{j=1}^n p(X^{(j)} = x^{*(j)} | y = c_k)$$

输出：新数据 $x^* = (x^{*(1)}, \dots, x^{*(n)})^T$ 所属类别， $y^* = f(x^*)$

2.6 离散变量的贝叶斯决策

- 贝叶斯决策

- **最小风险决策准则**: $\alpha^* = \arg \min_i R(\alpha_i | \mathbf{x})$

- 即，选择行为 α_i 使条件风险 $R(\alpha_i | \mathbf{x}) = \sum_{j=1}^C \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x})$ 最小。

- **最小错误率决策准则**: $\max(P(\omega_i | \mathbf{x}))$

- 即，通过最大后验概率(MAP)来最小化错误率。



- 离散特征变量:

- \mathbf{x} 是 m 个离散值 v_1, \dots, v_m 中的一个

- 如，医疗诊断(是否有某症状)，问卷调查(每个问题有2或多个选项)

- 概率密度函数 $p(\mathbf{x} | \omega_i) = p(x_1 x_2 \dots x_d | \omega_i)$

- (非参数、直方图表示)



独立的二值特征

考虑**两类问题**，其特征向量中的元素是二值的，且条件独立。

设 $\mathbf{x} = (x_1, \dots, x_d)^T$, $x_i = 1$ 或 0 , 且

$$p_i = P(x_i = 1 | \omega_1), \quad \Rightarrow P(x_i | \omega_1) = p_i^{x_i} (1 - p_i)^{1-x_i}$$

$$q_i = P(x_i = 1 | \omega_2) \quad \Rightarrow P(x_i | \omega_2) = q_i^{x_i} (1 - q_i)^{1-x_i}$$

因条件独立，则类条件概率密度为

$$P(\mathbf{x} | \omega_1) = \prod_{i=1}^d p_i^{x_i} (1 - p_i)^{1-x_i}$$

$$P(\mathbf{x} | \omega_2) = \prod_{i=1}^d q_i^{x_i} (1 - q_i)^{1-x_i}$$

- 似然比: $\frac{P(\mathbf{X}|\omega_1)}{P(\mathbf{X}|\omega_2)} = \prod_{i=1}^d \left(\frac{p_i}{q_i}\right)^{x_i} \left(\frac{1-p_i}{1-q_i}\right)^{1-x_i}$
- 判别函数: $g(\mathbf{x}) = \log \frac{P(\mathbf{X}|\omega_1)P(\omega_1)}{P(\mathbf{X}|\omega_2)P(\omega_2)} = \sum_{i=1}^d \left[x_i \ln \frac{p_i}{q_i} + (1-x_i) \ln \frac{1-p_i}{1-q_i} \right] + \ln \frac{P(\omega_1)}{P(\omega_2)}$

该判别函数关于 x_i 是线性的，写成，

$$g(\mathbf{x}) = \sum_{i=1}^d w_i x_i + w_0, \quad i = 1, 2, \dots, d$$

w_i 表征每个特征的判别性

$$\text{其中, } w_i = \ln \frac{p_i(1-q_i)}{q_i(1-p_i)}, \quad w_0 = \sum_{i=1}^d \ln \frac{1-p_i}{1-q_i} + \ln \frac{P(\omega_1)}{P(\omega_2)}$$

- 判决规则: 如果 $g(\mathbf{x}) > 0$ ，将 \mathbf{x} 归为 ω_1 ；否则，将 \mathbf{x} 归为 ω_2 。
- 判决面: $g(\mathbf{x}) = 0$

所定义的是一个将 ω_1 的顶点同 ω_2 的顶点分割开的超平面。


例2.3 手写字符识别

离散概型估计问题

基于二值数据的贝叶斯分类实现

1. 理论基础

所谓**二值数据**，即各样本的**每一特征只取1或0**。对于手写数字的分类问题，在对每个数字图形提取特征时，定义 $N \times N$ 模板；在本例中 $N=5$ ，将每个样本的长度和宽度5等分，构成一个 5×5 的模板，相当于将模板罩在对应的样本上，如下图所示，对于每一份内的像素个数进行累加统计，除以该模板每一份的面积总数。设阈值 $T=0.05$ ，模板所对应的元素黑像素占有率大于 T ，则特征值取1；否则取0。



实现步骤:

① 计算先验概率 $P(\omega_i)$, 先验概率可由各类的样本数和样本总数近似计算:

$$P(\omega_i) \approx N_i / N \quad i = 0, 1, 2, \dots, 9$$

其中 $P(\omega_i)$ 为类别是数字 i 的先验概率; N_i 为数字 i 的样本数; N 为样本总数。



② 先计算 \mathbf{x} 各分量的类条件概率 $P_j(\omega_i)$, 再计算 \mathbf{x} 的类条件概率 $P(\mathbf{x}|\omega_i)$:

$P_j(\omega_i)$ 表示样本 $\mathbf{x} (x_0, x_1, x_2, \dots, x_{24})$ 属于 ω_i 类, \mathbf{x} 的第 j 个分量为1 ($x_j = 1$) 的概率估计值。

$$P_j(\omega_i) = (\sum_{\substack{k=1 \\ \mathbf{x} \in \omega_i}}^{N_i} x_j^{(k)} + 1) / (N_i + 2)$$

$j = 0, 1, \dots, 24$ 离散概率估计

由此可计算,

$$P(x_j = 1 | \mathbf{x} \in \omega_i) = P_j(\omega_i) \quad i = 0, 1, 2, \dots, 9$$

$$P(x_j = 0 | \mathbf{x} \in \omega_i) = 1 - P_j(\omega_i) \quad j = 0, 1, 2, \dots, 24$$

所有属于第 i 类的样本,
第 j 个特征取1的总数

样本 \mathbf{x} 的类条件概率为,

$$P(\mathbf{x}|\omega_i) = P[\mathbf{x} = (x_0, x_1, x_2, \dots, x_{24}) | \mathbf{x} \in \omega_i]$$

$$P(\mathbf{x}|\omega_i) = P[\mathbf{x} = (x_0, x_1, x_2, \dots, x_{24}) | \mathbf{x} \in \omega_i] = \prod_{j=0}^{24} P(x_j = \alpha | \mathbf{x} \in \omega_i)$$

$i = 0, 1, \dots, 9$ 其中, $\alpha = 0$ 或 1 。

③应用贝叶斯公式求后验概率

$$P(\omega_i | \mathbf{x}) = \frac{P(\omega_i)P(\mathbf{x}|\omega_i)}{P(\omega_0)P(\mathbf{x}|\omega_0) + P(\omega_1)P(\mathbf{x}|\omega_1) + \dots + P(\omega_9)P(\mathbf{x}|\omega_9)}$$

$i = 0, 1, \dots, 9$

④后验概率的最大值的类别 (0~9) 就是手写数字的所属类别。

输入：训练数据集 $D = \{(x_1, y_1), \dots, (x_N, y_N)\}$ 各分量为离散型数据

过程：

(1) 计算先验概率 $p(y=c_k)$ 的极大似然估计：

$$\hat{p}(y=c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda}, k = 1, 2, \dots, K$$

其中 I 是指示性函数，若 $y_i = c_k$ ，则 $I(y_i = c_k) = 1$ ，否则 $I(y_i = c_k) = 0$

λ 是平滑项， $\lambda = 1$ 时则是拉普拉斯平滑，这里 $\lambda = 1$ 。

(2) 计算条件概率 $p(X^{(j)}=a_{jl}|y=c_k)$ 的极大似然估计（设每个单独输入的 n 维向量 x_i 的第 j 维特征 $x^{(j)}$ 可能的取值集合为 $\{a_{j1}, \dots, a_{jM_j}\}$ ）：

$$\hat{p}(X^{(j)}=a_{jl}|y=c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)}=a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + M_j \lambda}$$

其中 $l = 1, 2, \dots, M_j$; $k = 1, 2, \dots, K$; $\lambda = 1$

(3) 构造决策函数 $f(x)$ （根据贝叶斯决策，数据 $x^* = (x^{*(1)}, \dots, x^{*(n)})^T$ 的类别应判定为后验概率最大的类别）：

$$f(x^*) = \arg \max_{c_k} \hat{p}(y = c_k) \prod_{j=1}^n \hat{p}(X^{(j)} = x^{*(j)} | y = c_k)$$



输出：新数据 $x^* = (x^{*(1)}, \dots, x^{*(n)})^T$ 所属类别， $y^* = f(x^*)$

输出：新数据 $x^* = (x^{*(1)}, \dots, x^{*(n)})^T$ 所属类别， $y^* = f(x^*)$

小结：统计模式分类的基本框架

- 特征空间划分

- 判别函数(Discriminant function)、决策面(Decision surface)
- 生成模型(Generative model): $\mathbf{x} \rightarrow p(\mathbf{x}|\omega_i) \rightarrow g_i(\mathbf{x})$,
- 判别模型(Discriminative model): $\mathbf{x} \rightarrow g_i(\mathbf{x})$



生成模型

- 从一定的概率模型出发，把模式识别问题转化成概率模型估计问题
- 分类器设计实是对概率模型的估计
- 又称为基于(概率)模型的模式识别方法

判别模型

- 从要解决的问题和训练样本出发，直接求出判别函数
- 有些方法可事先确定判别函数的形式，通过训练样本确定其中的参数。
如，SVM，神经网络
- 有的甚至不用事先设计分类器，只确定分类原则，根据已知样本直接对未知样本进行分类。如 近邻法
- 也称为基于数据的模式识别方法

模式识别相关杂志和主流国际会议

- 模式识别相关杂志

- IEEE Trans. On PAMI TPAMI
- Journal of Machine Learning Research JMLR
- Artificial Intelligence AI
- International Journal of Computer Vision IJCV
- Pattern Recognition

- 主流国际会议

- IJCAI (International Joint Conference on Artificial Intelligence)
- CVPR (IEEE Conference on Computer Vision & Pattern Recognition)
- ICML (International Conference on Machine Learning)
- AAAI (AAAI Conference on Artificial Intelligence)
- ICCV (International Conference on Computer Vision)
- COLT / NIPS /KDD /ICLR

作业1

设计离散型或连续型朴素贝叶斯分类器。
二选一